HOUSING PRICE



Quel est le prix idéal pour cette maison?

ETAPES



Gridsearch pour trouver les meilleurs paramètres du modèle



Application de plusieurs modèles de régression et sélection



Retrait des variables inutiles, transformation de variables, dumification et standardisation



Analyse exploratoire, sélection des variables explicatives du prix de vente





Contexte et Objectifs du projet

CONTEXTE & AGENCE IMMOBILIÈRE FS



Contexte

- Historique de 1460 biens vendus
- Croître le chiffre d'affaire en optimisant le prix de vente des prochaines acquisitions



Objectifs

- Déterminer les caractéristiques à privilégier lors de nouveaux achats de biens pour augmenter le chiffre d'affaire
- Développer un outil permettant une estimation simple et rapide du prix de vente optimal de nos propriétés



ANALYSE EXPLORATOIRE



Objectif

Confirmer ou infirmer des hypothèses



Méthodologie

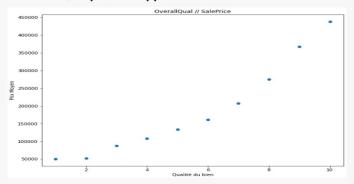
Mise en commun des résultats de :

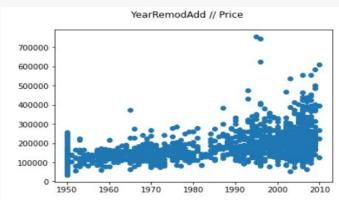
- graphiques de corrélation prix = f(variable)
- répartition des valeurs pour chaque variable
- nombre de valeurs manquantes

ANALYSE EXPLORATOIRE

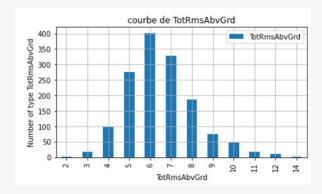


Recommendations/observations Graphs en appui





Répartition des valeurs des colonnes



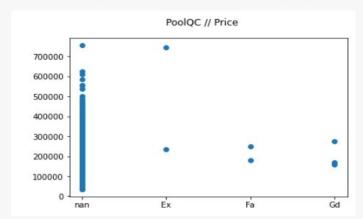


ANALYSE EXPLORATOIRE



Recommendations/observations Graphs en appui

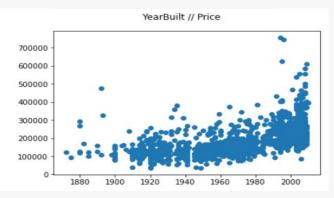
Piscine - répartition mauvaise sur le graphe

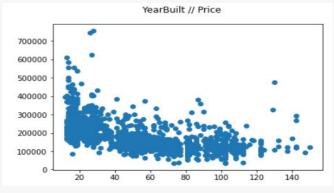


Mais avec des maisons similaire ayant ou non une piscine, on a une moyenne de prix:

- O maison sans piscine: 180k
- Omaison avec piscine: 280k

Changement des valeurs





Plus ancien -> moins chère

RECOMMANDATIONS



Acquérir des biens avec piscines augmenterait en moyenne le prix de vente de 100 000 €.



Acquérir des biens avec 4 chambres au maximum. Au-delà, le prix de vente diminue.



Acquérir des biens avec construit après 1990.



Acquérir des biens avec dont la surface par pièce est importante.

PRE-PROCESSING



Supression

des variables non explicatives du prix de vente : liste des variables

Enrichissement

Nom de colonnes

Transform

Transformation des variables restantes

Catégorisation

des variables explicatives : Nominale, ordinale, numérique Dummification, standardisation

to_drop = ["Fence", "YrSold", "MoSold", "Condition2", "KitchenAbvGr", "3SsnPorch", "PoolArea", "MiscVal", "SaleCondition", "Utilities", "Heating", "HeatingQC", "Street", "Alley", "GarageCond", "BsmtCond", "MiscFeature", "YearRemodAdd", "RoofMatl", "LandContour", "LotConfig", "Id", "Electrical", "MasVnrArea", "LotFrontage", "GarageYrBlt", "GarageQual", "PoolQC"]

MODEL ET CROSS-VALIDATION

- Cross validation paramètre :
- Division 4
- Métriques: mean square error
- Les modèles utilisés:
 Régression linéaire
 Decision tree
 Random Forest

Régression linéaire

array([-1.12125384e-01, -1.61692698e+19, -7.46847867e+19, -6.97993870e+18])

Random Forest

array([-0.14403395, -0.2282756, -0.17103888, -0.20346908])

Decision tree

aarray([-0.26003228, -0.34972067, -0.19561401, -0.25529931])

OPTIMISATION

Meilleur modèle : Random Forest Méthode d'optimisation : Gridsearch

```
parameters = {
'n_estimators':[80, 100, 150], 'max_depth': [4, 5, 6, 8],
'min_samples_split': [2,3]}
```

Résultats:

meilleur score: -0.14250268084417836

Meilleur estimateur:

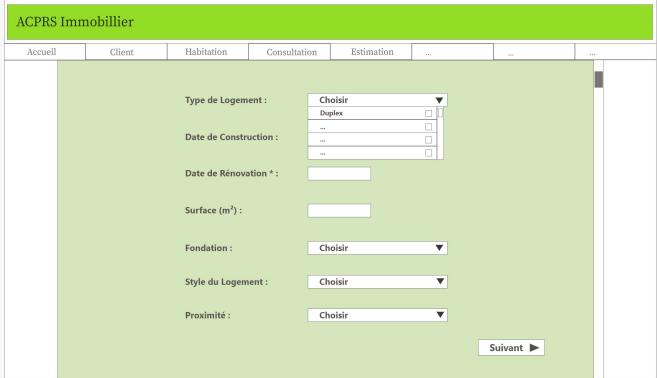
RandomForestRegressor(max_depth=8, min_samples_split=3, n_estimators=150)

result.best_score_ -0.14250268084417836

rclf.best_estimator_ RandomForestRegressor(max_depth=8, min_samples_split=3, n_estimators=150)

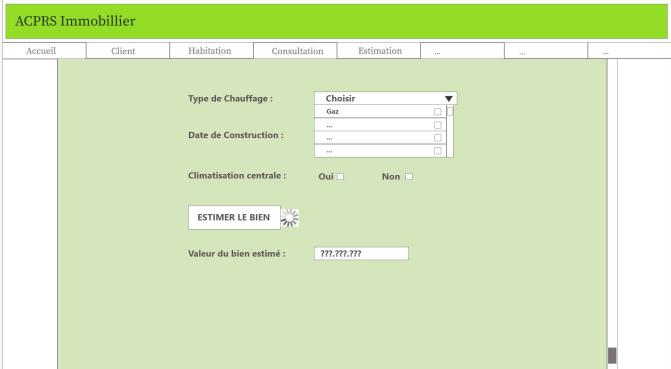
PRODUIT FINAL





PRODUIT FINAL





MERCIPOUR HOUSE PRICING VOTRE ATTENTION

N'hésitez si vous avez des questions